ĐỀ CƯƠNG CÔNG TRÌNH NGHIÊN CỨU KHOA HỌC SINH VIÊN
NĂM HỌC 2025 – 2026

1. <u>Tên đề tài</u>:

- Tiếng Việt: Phát triển mô hình học sâu đa mô thức ứng dụng XAI trong hỗ trợ chẩn đoán và tiên lượng bệnh u não.
- Tiếng Anh: Developing a Multimodal Deep Learning Model with XAI for Brain Tumor Diagnosis and Prognosis Support.

2. <u>Lý do chọn đề tài</u>:

- U não là tình trạng hình thành khối u bất thường trong não hoặc các mô xung quanh, có thể lành tính hoặc ác tính, ảnh hưởng đến chức năng não bộ và đe dọa tính mạng nếu không được điều trị kịp thời. Có nhiều loại u não nhưng nguy hiểm nhất là ung thư não – có khả năng xâm lấn nhanh chóng vào các mô lành xung quanh, di căn đến các bộ phận khác của cơ thể, và gây tử vong cao do não không thể tái tạo như các cơ quan khác.
- Các phương pháp truyền thống như chụp cộng hưởng từ (MRI), CT scan hoặc PET scan thì phụ thuộc nhiều vào kỹ năng chuyên môn của bác sĩ X-quang, dẫn đến khó khăn khi thiếu chuyên gia, và các ảnh của cùng một loại u não vẫn có thể trông khác nhau (Intraclass Variability) gây ra thách thức trong chuẩn đoán.
- Vì vậy, nghiên cứu này được thực hiện với mục đích triển khai một ứng dụng web trí tuệ nhân tạo đa mô thức kết hợp XAI (Explainable AI) để hỗ trợ chuẩn đoán u não một cách hiệu quả và minh bạch hơn.

3. <u>Mục tiêu nghiên cứu</u>:

- Mục tiêu chung:
  + Triển khai một ứng dụng web tích hợp khung làm việc đa mô thức kết hợp XAI để hỗ trợ chẩn đoán u não, bằng cách kết hợp YOLOv5, DenseNet169-ViT, FCNN/U-Net, và attention mechanism (fusion dữ liệu đa nguồn: MRI, hình ảnh mô bệnh học, RNA, lâm sàng).
  + Hiện thực hóa trên một ứng dụng web để hỗ trợ bác sĩ trong quy trình: tải lên MRI/WSI, phát hiện–phân đoạn–phân loại khối u, xếp hạng nguy cơ, tiên lượng thời gian sống còn, và diễn giải XAI ngay trên giao diện.
- Mục tiêu cụ thể:
  - Phát hiện và Phân đoạn khối u (trên ảnh MRI):
    + Phát hiện: Áp dụng mô hình YOLOv5 để đạt các chỉ số hiệu suất: chỉ số F1 ≥ 0,85 và Precision/Recall ≥ 0,90.
    + Phân đoạn: Áp dụng các mạng tích chập đầy đủ (FCNN) để đạt các chỉ số Dice ≥ 0,85 và IoU (Intersection over Union) ≥ 0,75 trên tập dữ liệu đã được gán nhãn.
  - Phân loại loại u (trên ảnh MRI):

    + Sử dụng mô hình lai DenseNet169-ViT để đạt độ chính xác (Accuracy) ≥ 92% - 95% và chỉ số F1 ≥ 0,85 cho từng lớp u. Đồng thời, các chỉ số đánh giá chuyên sâu như AUC (Area Under the Curve) và mAP (mean Average Precision) cũng sẽ được báo cáo.
- Phân tầng Nguy cơ và Tiên lượng sống còn (hợp nhất WSI + RNA-seq + lâm sàng):
    + Xây dựng mô hình hợp nhất dữ liệu đa phương thức để đạt chỉ số C-index ≥ 0,7.
    + Phân tầng bệnh nhân thành các nhóm nguy cơ có sự khác biệt thống kê đáng kể, với p-value của kiểm định log-rank < 0,05.
- Đánh giá Khả năng Giải thích (XAI):
    + Sử dụng các kỹ thuật như Grad-CAM, Grad-CAM++, Score-CAM, Layer-CAM để tạo bản đồ nhiệt, trực quan hóa các vùng mà mô hình AI đã chú ý trên ảnh MRI và WSI.
    + Tiến hành kiểm tra tính hợp lý (sanity check): các bác sĩ chuyên khoa sẽ đánh giá bản đồ nhiệt này để xác nhận rằng AI đang ra quyết định dựa trên các đặc trưng lâm sàng hợp lý.
    + Đánh giá tính hợp lý lâm sàng (clinical plausibility): ≥ 70% các trường hợp được bác sĩ chấm điểm ≥ 4/5, chứng minh mức độ tin cậy của lời giải thích.
- Hiệu quả triển khai:
    + Đảm bảo thời gian suy luận của mô hình trên các GPU phổ biến phải tương đối nhanh, đáp ứng yêu cầu của môi trường lâm sàng.
    + Giao diện demo của ứng dụng web phải đạt tỷ lệ sẵn sàng ≥ 95% trong suốt giai đoạn nghiệm thu nội bộ, đảm bảo tính ổn định cao.
    + Tỷ lệ lỗi của các API dịch vụ không được vượt quá 1%, thể hiện độ tin cậy của các luồng xử lý dữ liệu.
    + Toàn bộ dữ liệu được truyền tải qua giao thức HTTPS để mã hóa và bảo vệ khỏi các cuộc tấn công.
    + Hệ thống phải tự động ẩn danh tên tệp và các siêu dữ liệu khác để đảm bảo tính riêng tư của bệnh nhân. Hệ thống sẽ phân quyền người dùng rõ ràng, giới hạn truy cập chỉ cho những vai trò được cấp phép như nghiên cứu viên hoặc bác sĩ.
    + Toàn bộ ứng dụng web được đóng gói bằng Docker Compose, giúp dễ dàng triển khai trên các môi trường khác nhau.
    + Cung cấp tài liệu hướng dẫn chi tiết, cho phép hệ thống có thể được cài đặt trên các máy chủ ảo (VPS) hoặc máy trạm GPU cục bộ.
    + Thực hiện đánh giá và so sánh hiệu quả của mô hình đề xuất với các phương pháp tiếp cận khác đã được công bố, nhằm khẳng định giá trị và tính ưu việt của nghiên cứu.

4. <u>Đối tượng nghiên cứu</u>:

- Kiến thức về các loại u não: như u ác tính (glioblastoma (GBM)), u lành tính, u tuyến, u màng não, vv…

- Dữ liệu hình ảnh y khoa: MRI và CT scan từ bệnh nhân chẩn đoán u não, thu thập từ các bộ dữ liệu thực tế như Bangladesh Brain Cancer MRI Dataset, UCSF-PDGM, TCGA-GBM và CPTAC-GBM, với dữ liệu đa phương thức bổ sung (histo whole-slide images và RNA sequencing profiles).
- Các phương pháp học máy và học sâu: Convolutional Neural Networks (CNN) như DenseNet169, Vision Transformer (ViT), YOLOv5 cho phát hiện, định vị, FCNN/U-Net cho phân đoạn, attention-based deep learning cho fusion multimodal và XAI (Explainable AI) với các kỹ thuật như GradCAM để minh bạch hóa quyết định.
- Công cụ và thư viện xử lý ảnh: OpenCV cho tiền xử lý cơ bản, TensorFlow/PyTorch làm framework, pytorch-grad-cam cho XAI (GradCAM series).
- Công cụ web & viewer: FastAPI (backend phục vụ mô hình), React/Next.js (frontend), Cornerstone/OHIF (xem DICOM MRI), OpenSeadragon (xem WSI), MinIO/S3 (lưu trữ ảnh), PostgreSQL (metadata), Redis/Celery (hàng đợi tác vụ lớn). Các công cụ này gắn với mô hình YOLOv5–FCNN, DenseNet169-ViT, và fusion attention đã nêu.

5. <u>Ý nghĩa đề tài</u>:

- Vai trò: Nghiên cứu cung cấp một khung trí tuệ nhân tạo đa mô thức có khả năng giải thích (XAI), kết hợp đồng thời ảnh MRI, ảnh mô bệnh học toàn phiến (WSI), dữ liệu RNA-seq và thông tin lâm sàng. Điểm đặc biệt là mô hình không chỉ dừng lại ở mức thuật toán mà còn được chuyển giao thành ứng dụng web minh chứng, giúp kết quả nghiên cứu có tính khả dụng thực tế, gắn kết trực tiếp với hoạt động chẩn đoán hình ảnh và hội chẩn đa chuyên khoa.
- Tính ứng dụng: Ứng dụng web có thể được ứng dụng trực tiếp tại các khoa chẩn đoán hình ảnh ở các bệnh viện và cơ sở y tế, giúp hỗ trợ sàng lọc nhanh các ca bệnh, Theo dõi minh bạch bằng XAI và hỗ trợ phân tầng nguy cơ và tiên lượng sống còn.
- Hiệu quả kinh tế:
    - Giảm thời gian chẩn đoán, tăng hiệu suất làm việc cho các bác sĩ.
    - Phát hiện bệnh sớm giúp giảm chi phí điều trị lâu dài cho bệnh nhân và hệ thống y tế.
    - Tối ưu nguồn lực bằng việc triển khai trên nền tảng web gọn nhẹ, không đòi hỏi hạ tầng siêu máy tính, có thể vận hành trên máy chủ GPU phổ thông.
- Hiệu quả xã hội:
    - Nâng cao chất lượng dịch vụ y tế, mang công nghệ AI tiên tiến đến gần hơn với thực hành lâm sàng.
    - Mở rộng khả năng tiếp cận công cụ chẩn đoán hiện đại cho nhiều bệnh viện, kể cả ở tuyến dưới, nhờ mô hình ứng dụng web dễ triển khai.
    - Giảm thiểu các sai sót y khoa do yếu tố chủ quan, tăng cường sự chính xác trong chẩn đoán.
    - Mở ra cơ hội điều trị sớm và tăng tỷ lệ sống sót cho bệnh nhân mắc bệnh u não.

6. <u>Câu hỏi nghiên cứu</u>:

- Mô hình AI kết hợp YOLOv5, DenseNet169-ViT và FCNN/U-Net có đạt được độ chính xác (Accuracy) ≥ 98.5% và điểm F1 từng lớp ≥ 0.90 trong việc phân loại các loại u não chính (GBM, u màng não, u tuyến yên, u thần kinh đệm lành tính) từ ảnh MRI hay không?
- Việc tích hợp dữ liệu đa phương thức (hình ảnh mô bệnh học WSI và dữ liệu RNA sequencing) với hình ảnh MRI thông qua cơ chế attention-based fusion có cải thiện đáng kể khả năng dự báo tiên lượng sống của bệnh nhân, thể hiện qua chỉ số C-index ≥ 0.75, so với việc chỉ sử dụng dữ liệu MRI đơn thuần hay không?
- Các kỹ thuật XAI (như Grad-CAM, Grad-CAM++) có thể tạo ra các bản đồ nhiệt trùng khớp với các đặc điểm lâm sàng quan trọng (ví trí khối u, vùng xâm lấn) trên ảnh MRI và WSI, từ đó giúp các chuyên gia y tế tin tưởng và hiểu được cơ sở cho quyết định của mô hình với tỷ lệ ≥ 80% trường hợp được đánh giá có tính hợp lý cao hay không?
- Mô hình phát hiện khối u (YOLOv5) và mô hình phân đoạn (FCNN/U-Net) có đạt được các chỉ số kỹ thuật mục tiêu (F1 ≥ 0.90 cho YOLOv5 và Dice ≥ 0.88 cho FCNN) trên các bộ dữ liệu thử nghiệm độc lập, chứng tỏ tính ổn định và khả năng tổng quát hóa của chúng hay không?
- Hệ thống đề xuất có khả năng hoạt động như một công cụ hỗ trợ ra quyết định hiệu quả, giúp rút ngắn thời gian sàng lọc và cung cấp dự đoán tiên lượng có ý nghĩa thống kê (p-value < 0.001 trong kiểm định log-rank) cho các bác sĩ lâm sàng trong quy trình chẩn đoán và điều trị u não hay không?

7. <u>Tổng quan tài liệu - Nghiên cứu liên quan</u>:

Trong những năm gần đây, ứng dụng Trí tuệ nhân tạo (AI), đặc biệt là Học sâu (Deep Learning), trong chẩn đoán hình ảnh y tế đã có những bước tiến vượt bậc. Nghiên cứu về chẩn đoán u não cũng phát triển theo ba hướng tiếp cận chính:

- Các mô hình dựa trên ảnh MRI đơn phương thức: Đây là hướng tiếp cận phổ biến nhất. Các nghiên cứu như của Ahsan et al. (2020) và Nahiduzzaman et al. (2025) tập trung vào việc sử dụng các kiến trúc CNN (VGG, ResNet) và Hybrid ML-DL để phân loại khối u từ ảnh MRI với độ chính xác cao (trên 95%). Các nghiên cứu gần đây như "Accurate and real-time brain tumour detection and classification using optimized YOLOv5 architecture" (2025) đã chứng minh hiệu quả của YOLOv5 trong việc phát hiện và phân loại khối u theo thời gian thực. Tuy nhiên, hạn chế của các phương pháp này là chỉ khai thác thông tin từ một nguồn dữ liệu duy nhất (MRI), chưa tận dụng được các đặc trưng sinh học ở cấp độ mô và phân tử, vốn rất quan trọng để tiên lượng bệnh.
- Các mô hình đa phương thức (Multimodal) cho tiên lượng: Để khắc phục hạn chế trên, hướng nghiên cứu tích hợp dữ liệu đa phương thức đã xuất hiện. Công trình "Multimodal deep learning to predict prognosis in adult and pediatric brain tumors" (2023) trên *Communications Medicine* là một ví dụ điển hình, kết hợp hình ảnh MRI với dữ liệu mô bệnh học (WSI) để dự đoán tiên lượng cho bệnh nhân u não. Nghiên cứu này chỉ ra rằng việc kết hợp đa phương thức giúp cải thiện đáng kể độ chính xác trong dự báo so với chỉ dùng MRI. Tuy vậy, các mô hình này thường phức tạp, đòi hỏi lượng dữ liệu lớn và chưa chú trọng nhiều đến tính giải thích được.

- Xu hướng tích hợp Explainable AI (XAI): Với yêu cầu ngày càng cao về tính minh bạch trong y tế, XAI đã trở thành một thành phần không thể thiếu. Các nghiên cứu như Alam Khandaker et al. (2023), Aiya et al. (2025), và Lamba et al. (2025) đều nhấn mạnh tầm quan trọng của việc tích hợp các kỹ thuật như Grad-CAM, LIME, hoặc SHAP để tạo ra các bản đồ nhiệt, giúp bác sĩ hiểu được lý do đằng sau chẩn đoán của AI. Điều này xây dựng niềm tin và tạo điều kiện cho sự chấp nhận của các chuyên gia lâm sàng.

Mặc dù đã có nhiều tiến bộ, vẫn tồn tại một khoảng trống rõ rệt: Chưa có một khung làm việc hoàn chỉnh nào kết hợp một cách có hệ thống cả ba yếu tố: (1) pipeline xử lý từ phát hiện, phân đoạn đến phân loại trên MRI; (2) tích hợp sâu dữ liệu đa phương thức (MRI, WSI, RNA-seq) cho tiên lượng; và (3) nhấn mạnh tính giải thích (XAI) xuyên suốt toàn bộ pipeline.

8. <u>Phạm vi/ giới hạn nghiên cứu</u>:

- Phạm vi nghiên cứu
  + Dữ liệu: Hình ảnh MRI/FLAIR và CT scan từ các bộ dữ liệu thực tế (Bangladesh Brain Cancer MRI Dataset với 6.056 hình ảnh, UCSF-PDGM, TCGA-GBM và CPTAC-GBM subsets với ~500-1.000 bệnh nhân, bao gồm dữ liệu đa phương thức như whole-slide histopathological images và RNA sequencing profiles). Phạm vi giới hạn ở bệnh nhân trưởng thành (trên 18 tuổi) với các loại u não chính: glioblastoma (GBM), u glial lành tính, adenomas, meningeal, và u di căn.
  + Nhiệm vụ:
    - Chuẩn đoán trên ảnh MRI: Phát hiện, phân đoạn và phân loại, định độ u não.
    - Phân tầng nguy cơ: Hợp nhất WSI (ảnh mô bệnh học H&E) và RNA-seq và dữ liệu lâm sàng bằng mạng attention-based để dự báo sống còn thông qua risk score, C-index, Kaplan–Meier, …
    - Giải thích mô hình (XAI): Grad-CAM, Grad-CAM++, Score-CAM.
    - Đánh giá mô hình phân loại thông qua các thông số (Accuracy/ precision/ recall/ F1-Score, AUC). Đánh giá độ chính của dự đoán, tiên lượng sống của bệnh nhân.
  + Kỹ thuật:
    - Mô hình: YOLOv5, FCNN kiểu U-Net/DeepLab, DenseNet169 + Vit, attention- based multimodal fusion.
    - Các thuật toán huấn luyện và tối ưu: RMSProp, NRMSProp,...
    - XAI: Grad-CAM, Grad-CAM++, Score-CAM, Layer-CAM,...
  + Ứng dung:
    - Ứng dụng web dùng cho mục đích nghiên cứu, giảng dạy và hỗ trợ chuyên gia; không thay thế quyết định lâm sàng, không tuyên bố đạt chuẩn thiết bị y tế (FDA/CE).
- Giới hạn:
  + Chỉ sử dụng dữ liệu từ các nguồn công khai (Mỹ/Bangladesh-centric), có thể gây bias về dân số (thiếu đa dạng châu Á/Phi), không bao gồm dữ liệu trẻ em hoặc u lành tính hiếm gặp.

+ Nghiên cứu hiện tại tập trung vào việc kết hợp các dữ liệu đa phương thức dựa trên hình ảnh bao gồm chụp cộng hưởng từ (MRI), mô bệnh học (histology) và dữ liệu RNA. Mặc dù đây là một bước tiến quan trọng, nghiên cứu vẫn chưa tích hợp các loại dữ liệu phức tạp hơn như video theo thời gian thực hay dữ liệu hệ gen đầy đủ (ví dụ: các đột biến DNA).
+ Thời gian xử lý có thể chậm trên hardware thông thường.
+ Không đánh giá tác động dài hạn: Nghiên cứu chỉ tập trung vào việc chẩn đoán và tiên lượng tại một thời điểm nhất định, mà không theo dõi diễn biến của bệnh nhân trong 5 năm hoặc lâu hơn. Điều này có nghĩa là mô hình không thể dự đoán được các kết quả lâm sàng dài hạn như tỷ lệ tái phát bệnh hoặc thời gian sống còn của bệnh nhân.
+ Phụ thuộc vào chất lượng dữ liệu gốc: Hiệu suất của mô hình AI phụ thuộc hoàn toàn vào chất lượng của dữ liệu đầu vào. Nếu hình ảnh mô bệnh học bị nhiễu, mờ, hoặc không được chuẩn bị đúng cách, mô hình sẽ không thể trích xuất các đặc trưng chính xác, dẫn đến kết quả chẩn đoán sai lệch.

9. <u>Nội dung/ phương pháp nghiên cứu</u>:

Nghiên cứu sẽ được thực hiện theo các bước sau:

1. Thu thập và tiền xử lý dữ liệu:
   - Sưu tầm các bộ dữ liệu ảnh MRI/CT não từ các nguồn uy tín: như tập dữ liệu Bangladesh Brain Cancer MRI Dataset gồm 6.056 ảnh MRI não bệnh nhân, ảnh MRI trước phẫu thuật của bệnh nhân glioma từ Đại học California San Francisco (UCSF- PDGM), một phần ảnh MRI từ dự án The Cancer Genome Atlas về GBM (TCGA-GBM),…
   - Tập các ảnh mô bệnh học (WSI) Từ các cơ sở dữ liệu TCGA-GBM và CPTAC, khai thác dữ liệu RNA sequencing (RNA-seq) của bệnh nhân GBM từ TCGA và CPTAC,...
   - Thực hiện các bước tiền xử lý như chuẩn hóa, thay đổi kích thước ảnh, tăng cường dữ liệu, giảm chiều dữ liệu để cải thiện chất lượng và sự đa dạng của dữ liệu đầu vào.
2. Thực hiện phát hiện, phân đoạn và phân loại trên ảnh MRI giúp phân loại sớm :
   - Trên mỗi ảnh MRI sử dụng mô hình YOLOv5 để phát hiện liệu có khối u hay không và xác định vị trí của khối u.
   - Sau khi biết vùng tổng quát của khối u từ YOLOv5 thì tiến hành sử dụng FCNN (U-Net hoặc DeepLab tùy chỉnh) tiến hành phân đoạn từng pixel ảnh để tạo ảnh mặt nạ (mask) chi tiết của khối u.
   - Sau khi có mặt nạ của khối u từ quá trình phân đoạn, chúng tôi sử dụng một mạng nơ-ron tích chập sâu như DenseNet169 với các kết nối dày đặc. Kiến trúc này giúp lan truyền thông tin hiệu quả, từ đó trích xuất các đặc trưng chi tiết của khối u như mức độ xâm lấn, tính chất viền khối u và phù não.
   - Tiếp theo, chúng tôi tích hợp thêm Vision Transformer (ViT). Module này hoạt động bằng cách chia các đặc trưng ảnh thành các mảng nhỏ, sau đó tạo các biểu diễn số hóa. Nó sử dụng cơ chế tự-chú ý đa đầu (multi-head self-attention) để nắm bắt các mối liên hệ tổng thể giữa các vùng khác nhau

của ảnh. Ví dụ, nó có thể nhận biết mối liên kết giữa vùng trung tâm khối u với vùng phù não bao quanh, hoặc sự dịch chuyển của đường giữa não do khối u gây ra.

- Cuối cùng, chúng tôi kết hợp kết quả từ cả DenseNet (đặc trưng cục bộ) và ViT (đặc trưng toàn cục) bằng cách nối chúng lại với nhau. Vectơ kết hợp này được đưa qua các lớp kết nối đầy đủ để mô hình đưa ra dự đoán phân loại cuối cùng.
- Các nhãn phân loại ở đây bao gồm: U thần kinh đệm lành tính (như u sao bào mức độ thấp, u tế bào hình sao độ I/II), U màng não (meningioma, thường lành tính), U tuyến yên (pituitary adenoma, lành tính), và U ác tính GBM (glioblastoma và các phân nhóm ác tính tương tự). Chúng tôi chọn 4 nhóm này vì chúng bao hàm các dạng u não thường gặp.
- Trong quá trình huấn luyện mô hình, một trong những thách thức lớn nhất là sự mất cân bằng dữ liệu giữa các lớp (class imbalance). Ví dụ cụ thể, số lượng ảnh về u não nguyên bào thần kinh đệm (GBM) có thể thấp hơn đáng kể so với u màng não (meningioma). Tình trạng này có thể khiến mô hình thiên vị các lớp chiếm đa số, làm giảm hiệu suất phân loại đối với các lớp thiểu số.hóa mô hình phân loại. Bộ tối ưu này đã được chứng minh giúp hội tụ tốt trên dữ liệu y khoa mất cân bằng, cải thiện độ ổn định khi huấn luyện.
- Để giải quyết vấn đề này, chúng tôi đã sử dụng bộ tối ưu RMSProp (Root Mean Square Propagation) với một cải tiến quan trọng là tích hợp Nesterov momentum. Sự kết hợp này tạo nên một biến thể được gọi là NRMSProp, được thiết kế để tối ưu hóa mô hình phân loại.

3. Huấn luyện mô hình dự báo tiên lượng đa modal (MRI, WSI(Whole Slide Image) và chuỗi RNA):
    - Để dự đoán thời gian sống thêm (overall survival) và phân tầng nguy cơ cho bệnh nhân, chúng tôi phát triển một mô hình deep learning chú ý đặc biệt để tích hợp dữ liệu hình ảnh mô bệnh học, dữ liệu gene và dữ liệu lâm sàng:
        + Trích xuất đặc trên dữ liệu WSI: Đối với mỗi bệnh nhân mắc u nguyên bào thần kinh đệm (GBM), chúng tôi sử dụng một ảnh mô bệnh học (WSI) để trích xuất các đặc trưng của khối u. Do kích thước khổng lồ của ảnh WSI, chúng tôi áp dụng một mạng nơ-ron tích chập (CNN) để xử lý từng mảng nhỏ của ảnh. Sau đó, các đặc trưng từ những mảng này được tổng hợp để tạo thành một biểu diễn duy nhất cho toàn bộ khối u. Ngoài ra, chúng tôi còn phát triển một cơ chế cross-attention để kết nối thông tin giữa ảnh MRI và ảnh mô bệnh học đối với những bệnh nhân có cả hai loại dữ liệu này. Cách tiếp cận này tương tự như phương pháp iGISM, sử dụng cơ chế đồng chú ý (co-attention) được hướng dẫn bởi ảnh MRI. Điều này giúp đồng bộ và tận dụng các thông tin liên quan giữa ảnh MRI trước phẫu thuật và lát mô của khối u. Phương pháp này đặc biệt hiệu quả vì ảnh MRI cung cấp cái nhìn tổng quan về khối u khi còn trong cơ thể sống, trong khi ảnh mô bệnh học lại cung cấp các chi tiết ở cấp độ tế bào của cùng một khối u đã được lấy ra ngoài (ex vivo).

+ Trích xuất đặc trưng trên dữ liệu RNA-seq: Đối với dữ liệu giải trình tự RNA-seq, chúng tôi xử lý thông qua một mạng nơ-ron chuyên biệt để rút gọn thành một vectơ đặc trưng súc tích, chỉ giữ lại những thông tin sinh học quan trọng nhất. Để tối ưu hóa quá trình này, chúng tôi cũng áp dụng một cơ chế tự chú ý (self-attention) trên các gen. Cơ chế này cho phép mô hình tự động tập trung vào những gen hoặc chuỗi gen (pathway) có vai trò quyết định đến tiên lượng của bệnh nhân. Cụ thể, mô hình có thể tự nhận biết và ưu tiên các gen liên quan đến quá trình phân bào hoặc gen có ảnh hưởng đến vi môi trường miễn dịch của khối u, những yếu tố đã được chứng minh có mối liên hệ mật thiết với kết quả điều trị và thời gian sống của bệnh nhân.
+ Tích hợp và dự đoán sống còn: Sau khi trích xuất đặc trưng từ dữ liệu hình ảnh (MRI, WSI) và dữ liệu hệ gen, chúng tôi hợp nhất các đặc trưng này trong một kiến trúc mạng nơ-ron chuyên biệt, được thiết kế để xử lý đa phương thức. Kiến trúc này được xây dựng như một mạng có nhiều nhánh: hai nhánh mạng nơ-ron tích chập (CNN) cho ảnh WSI và MRI, cùng một nhánh riêng cho dữ liệu gen. Tất cả các nhánh này sẽ hội tụ tại một tầng hợp nhất cuối cùng.Tại tầng hợp nhất, chúng tôi sử dụng các lớp multi-head attention để học cách pha trộn thông tin một cách thông minh. Cơ chế này cho phép các vectơ đặc trưng từ hình ảnh và gen tương tác với nhau để phát hiện các mối liên kết ẩn. Ví dụ, mô hình có thể nhận ra mối quan hệ giữa việc bệnh nhân có biểu hiện gen phân bào cao với việc hình ảnh mô bệnh học cho thấy mật độ tế bào u cao.

- Đánh giá tiên lượng:
  + Chúng tôi đánh giá mô hình trên các tập bệnh nhân độc lập (ví dụ lấy một phần TCGA-GBM làm tập kiểm thử). C-index được dùng làm thước đo chính, phản ánh khả năng mô hình xếp hạng đúng giữa các thời gian sống của bệnh nhân.
  + Ngoài C-index, chúng tôi cũng tính Brier score tích hợp (IBS) để đo lường độ chuẩn xác theo thời gian.
- Để trực quan hóa khả năng phân tầng nguy cơ, chúng tôi chia bệnh nhân thành 2 nhóm dựa trên điểm nguy cơ dự đoán (nhóm nguy cơ cao và nguy cơ thấp, thường lấy median risk hoặc một threshold tối ưu). Sau đó vẽ đường cong Kaplan–Meier cho hai nhóm và thực hiện phép kiểm định log-rank.
- Sử dụng kĩ thuật XAI và trực quan hóa để xác thực quyết định:
  + Sử dụng Grad-CAM/Grad-CAM++: Đây là một kỹ thuật tạo ra bản đồ nhiệt (heatmap) ngay trên ảnh. Vùng nào càng sáng, mô hình càng chú ý vào đó để đưa ra quyết định.
  + Mục đích: Để xác nhận rằng mô hình thực sự dựa vào vùng khối u, rìa khối u, hoặc phù não để chẩn đoán.
  + Ý nghĩa: Khi bản đồ nhiệt trùng khớp với những gì bác sĩ X-quang cũng quan sát, nó cho thấy mô hình đang đưa ra quyết định dựa trên các đặc trưng y học hợp lý, không phải dựa vào các yếu tố ngẫu nhiên khác.

+ Sau khi có kết quả phân tích, mô hình XAI sẽ chuyển đổi các con số và tọa độ pixel thành ngôn ngữ thông thường. Điều này biến mô hình thành một hệ hỗ trợ quyết định thân thiện, cung cấp cả kết quả lẫn lý do cho bác sĩ, khác biệt hẳn với nhiều mô hình đen trước đây.

4. Module Triển khai và Giao diện người dùng:
   - Tải lên và tiền xử lý: Người dùng tải lên dữ liệu hình ảnh (MRI/WSI) hoặc dữ liệu gen. Hệ thống sẽ thực hiện các bước kiểm tra ban đầu để đảm bảo tính toàn vẹn của tệp và ẩn danh thông tin bệnh nhân. Dữ liệu sau đó được lưu trữ an toàn trên dịch vụ lưu trữ đám mây.
   - Gọi API và Suy luận: Sau khi dữ liệu được lưu trữ, một yêu cầu API chuẩn hóa (REST/JSON) sẽ được gửi đến máy chủ xử lý.
   - Tạo giải thích và Điểm nguy cơ: Kết quả từ các mô hình sẽ được xử lý để sinh ra các bản đồ mặt nạ (mask), bản đồ nhiệt CAM (Class Activation Map) và tính toán điểm nguy cơ (risk score) thông qua cơ chế hợp nhất.
   - Giao diện trực quan hóa XAI:
     + Trình Xem Ảnh Chuyên dụng: Trình xem cho phép người dùng tương tác trực tiếp với hình ảnh và các lớp phủ phân tích. Các lớp phủ (overlay) như bản đồ mặt nạ và bản đồ nhiệt giải thích sẽ được hiển thị trực tiếp lên ảnh gốc, giúp bác sĩ so sánh trực quan giữa vị trí khối u và lý do mà AI đưa ra quyết định.
     + Bảng điều khiển và Biểu đồ Phân tích: Giao diện còn có một bảng điều khiển động, cung cấp các thông số quan trọng dưới dạng biểu đồ và danh sách dễ hiểu. Bao gồm biểu đồ hiển thị điểm nguy cơ (risk score) của bệnh nhân, bảng xếp hạng các yếu tố có ảnh hưởng lớn nhất (ví dụ: gen KI-67) và một đoạn văn bản tóm tắt, giải thích ngắn gọn bằng ngôn ngữ phù hợp với từng đối tượng (bác sĩ hoặc bệnh nhân).
   - Quản lý dữ liệu và nhật ký: Tất cả siêu dữ liệu và kết quả suy luận sẽ được lưu trữ trong cơ sở dữ liệu để truy xuất và phân tích sau này. Hệ thống cũng ghi lại nhật ký truy cập và hoạt động để đảm bảo tính minh bạch và có thể truy vết.
5. Phân tích kết quả và kết luận:
   - Phân tích các trường hợp mô hình dự đoán đúng/sai để hiểu rõ hơn về khả năng và hạn chế của nó.
   - Viết báo cáo tổng kết quá trình thực hiện, kết quả đạt được và đề xuất hướng phát triển trong tương lai.

10. <u>Dự kiến kết quả/ Đề suất giải pháp</u>:

- Kết quả:
  - Một module ứng dụng web được triển khai dưới dạng demo. Ứng dụng này sẽ minh họa cách hệ thống hoạt động, cho phép người dùng tải lên dữ liệu để nhận kết quả suy luận. Giao diện người dùng sẽ trực quan hóa các giải thích từ XAI, giúp người dùng dễ dàng hiểu được lý do đằng sau các chẩn đoán của AI.
  - Một mô hình AI đa phương thức hoàn chỉnh, được huấn luyện và tinh chỉnh, có khả năng thực hiện các nhiệm vụ: phát hiện, phân đoạn và phân loại u não trên ảnh MRI, cũng như phân tầng nguy cơ dựa trên dữ liệu WSI, RNA và lâm

sàng. Mô hình này sẽ được cung cấp dưới dạng mã nguồn và trọng số đã huấn luyện để các nhà nghiên cứu khác có thể tái hiện và phát triển.
- Báo cáo chi tiết về hiệu suất của mô hình, bao gồm các chỉ số như độ chính xác, chỉ số F1, AUC, và C-index. Các kết quả này sẽ được so sánh một cách toàn diện với các mô hình tương đương hoặc các phương pháp tiếp cận đã có trước đây để khẳng định tính mới và giá trị của đề tài.
- Bài báo khoa học (dự kiến) để đăng tại hội nghị sinh viên nghiên cứu khoa học.

● Đề xuất giải pháp:
- Giải pháp dữ liệu:
  + Chuẩn hóa liên cơ sở: Dữ liệu hình ảnh từ các cơ sở khác nhau thường có sự khác biệt về đặc điểm kỹ thuật. Chúng tôi sẽ áp dụng các phương pháp chuẩn hóa tiên tiến như chuẩn hóa Z-score và cLAHE cho dữ liệu MRI, cùng với chuẩn hóa màu nhuộm (stain normalization) sử dụng các thuật toán như Macenko hoặc Vahadane cho ảnh WSI. Dữ liệu gen sẽ được chuẩn hóa liên cơ sở bằng phương pháp ComBat-harmonization để giảm thiểu sai lệch.
  + Xử lý Mất cân bằng Dữ liệu: Để khắc phục tình trạng mất cân bằng giữa các lớp, chúng tôi sẽ sử dụng các kỹ thuật như lấy mẫu cân bằng lớp (class-balanced sampling), tăng trọng số (re-weighting), hoặc tạo dữ liệu giả lập cho lớp thiểu số (minority oversampling) có kiểm soát.
  + Ghép cặp Dữ liệu đa phương thức: Quá trình ghép cặp dữ liệu từ các nguồn khác nhau (MRI, WSI, gene) sẽ được thực hiện một cách chặt chẽ, kiểm tra tính nhất quán của ID bệnh nhân và thời điểm lấy mẫu để loại trừ các bản ghi không đáng tin cậy.
  + Tách Tập Dữ liệu Nghiêm ngặt: Các tập dữ liệu huấn luyện, thẩm định và kiểm thử sẽ được tách theo bệnh nhân hoặc cơ sở y tế để tránh hiện tượng rò rỉ dữ liệu, đảm bảo kết quả đánh giá phản ánh chính xác hiệu suất của mô hình.
- Giải pháp thẩm định:
  + Mô hình sẽ được đánh giá trên các bộ dữ liệu độc lập từ nhiều cơ sở khác nhau. Điều này giúp đo lường mức độ suy giảm hiệu suất và xác định nguyên nhân (nếu có), từ đó đảm bảo tính tổng quát của mô hình.
  - Calibration & Uncertainty: Chúng tôi sẽ sử dụng các phương pháp như hiệu chỉnh nhiệt độ (temperature scaling) và ECE/Brier score để đánh giá tính hợp lý của các dự đoán. Các phương pháp như Monte Carlo Dropout (MC-Dropout) hoặc Ensemble cũng sẽ được áp dụng để ước lượng độ bất định của mô hình, giúp hiển thị độ tin cậy kèm theo mỗi dự đoán.
  - Một nghiên cứu nhỏ sẽ được tiến hành với sự tham gia của một nhóm bác sĩ X-quang và giải phẫu bệnh để đánh giá tốc độ và mức độ đáng tin cậy của hệ thống.

11. <u>Kế hoạch thực hiện tiến độ dự kiến</u>:

Tháng	Công việc thực hiện	Kết quả dự kiến	Tiến độ
09/2025	- Bắt đầu triển khai nghiên cứu. - Tổng quan tài liệu, xác định hướng tiếp cận chi tiết. - Tìm kiếm và đánh giá các bộ dữ liệu hình ảnh y tế (MRI, WSI, RNA-seq) phù hợp. - Khảo sát và lựa chọn công nghệ web phù hợp.	- Nắm vững kiến thức nền tảng về AI và công nghệ web. - Xác định rõ phương pháp học máy (CNN, Transfer Learning) và các công cụ (TensorFlow, PyTorch) sẽ sử dụng. - Lựa chọn được bộ dữ liệu chính cho đề tài. - Xác định được stack công nghệ cho việc triển khai.	10%
10/2025	- Viết và hoàn thiện đề cương chi tiết. - Ngày 15/10: Đăng ký đề tài và nộp đề xuất kinh phí. - Tham gia triển lãm nghiên cứu khoa học (nếu có).	- Đề cương chi tiết được hoàn thiện và nộp đúng hạn.	20%
11/2025	- Ngày 01/11: Chờ Khoa Công nghệ Thông tin duyệt đề tài. - Ngày 20/11: Chờ được duyệt đề tài cấp trường. - Chỉnh sửa đề cương (nếu có yêu cầu từ hội đồng)	- Đề tài được phê duyệt cấp Khoa và cấp Trường để bắt đầu thực hiện.	25%
12/2025 - 02/2026	- Nhận kinh phí (sau khi được duyệt). - Thu thập và tiền xử lý dữ liệu (MRI, WSI, RNA-seq). - Xây dựng và huấn luyện mô hình chẩn đoán trên MRI phiên bản đầu tiên (YOLOv5, FCNN, DenseNet-ViT). - Song song: Bắt đầu phát triển backend. - Thiết kế kiến trúc hệ thống web.	- Hoàn thành giai đoạn chuẩn bị dữ liệu. - Xây dựng thành công mô hình cơ bản. - Backend có thể nhận và lưu trữ file ảnh. - Đề tài được thông qua nghiệm thu sơ bộ và nhận khen thưởng (nếu có).	50%

	- Xây dựng các API cơ bản (upload, quản lý file). - Báo cáo tiến độ hằng tháng. - Ngày 15/01: Chuẩn bị và báo cáo nghiệm thu sơ bộ cấp khoa.		

03/2026 - 05/2026	- Tối ưu hóa mô hình MRI, tích hợp XAI (Grad-CAM).
	- Đánh giá hiệu suất mô hình với các số liệu chi tiết.
	- Bắt đầu viết báo cáo tổng kết đề tài.
	- Song song: Phát triển frontend và tích hợp.
	  - Xây dựng giao diện người dùng.
	  - Tích hợp mô hình chẩn đoán MRI đã ổn định vào backend API.
	  - Kết nối frontend với backend.
	- Báo cáo tiến độ hàng tháng.
		- Mô hình được tinh chỉnh và đạt độ chính xác mục tiêu.
		- Ứng dụng web có thể demo luồng chẩn đoán trên MRI: upload ảnh, nhận kết quả phân loại và heatmap XAI.
			70%

05/2026	- Hoàn thiện báo cáo.
	- Hoàn tất công trình theo kế hoạch nghiệm thu cấp khoa.
	- Song song: Hoàn thiện và đóng gói ứng dụng web.
	  - Tích hợp mô hình tiên lượng vào backend (nếu kịp tiến độ).
	  - Tinh chỉnh giao diện, sửa lỗi.
	  - Viết tài liệu hướng dẫn và đóng gói bằng Docker.
		- Mô hình MRI và mô hình tiên lượng đạt độ chính xác mục tiêu.
		- Ứng dụng web có thể demo luồng chẩn đoán trên MRI: upload ảnh, nhận kết quả phân loại và heatmap XAI
		- Hoàn thành bản thảo của báo cáo tổng kết.
			90%

06/2026	- Báo cáo nghiệm thu, chỉnh sửa và nộp công trình theo yêu cầu Hội đồng nghiệm thu cấp khoa. - Triển khai ứng dụng web lên máy chủ công cộng để	- Ứng dụng web hoạt động ổn định, sẵn sàng để demo. - Hoàn tất công trình theo kế hoạch. - Báo cáo nghiệm thu, chỉnh sửa và nộp công trình theo	100%

	hội đồng truy cập và dùng thử.	yêu cầu Hội đồng nghiệm thu cấp Khoa. - Có đường link web demo hoạt động.	
07/2026	- Ngày 15/07: Nghiệm thu đề tài cấp Trường. - Báo cáo cấp Trường; Chuẩn bị hồ sơ dự giải các cấp (nếu đề tài đạt kết quả tốt).	- Báo cáo cấp Trường - Chuẩn bị hồ sơ dự giải các cấp (nếu có).	X

12. <u>Tài liệu tham khảo:</u>

Alam Khandaker, M.A. *et al.* (2023). *From Images to Insights: Transforming Brain Cancer Diagnosis with Explainable AI. arXiv preprint arXiv:2501.05426*

Nahiduzzaman, M. *et al.* (2025). *A hybrid explainable model based on advanced ML and DL for classifying brain tumors using MRI. Scientific Reports, 15*, 1649

Aiya, A.J. *et al.* (2025). *Optimized deep learning for brain tumor detection: a hybrid approach with attention mechanisms and clinical explainability. Scientific Reports, 15*, 31386

Lamba, K. *et al.* (2025). *Synergizing XAI with hybrid model for enhanced brain tumor detection in healthcare. Scientific Reports, 15*, 20489

Multimodal deep learning to predict prognosis in adult and pediatric brain tumors. Communications Medicine (Nature), 3, 57 (2023)

Accurate and real-time brain tumour detection and classification using optimized YOLOv5 architecture. Scientific Reports, 15, Article no. 20277 (2025)

Ahsan, M. *et al.* (2020). *Brain Tumor Classification and Segmentation on MRIs. International Journal of Computer Applications*, 175(25), 19-27.

13. Dự trù kinh phí thực hiện:

	Diễn giải	Số tiền
1.	Chi phí sử dụng tài nguyên tính toán (ví dụ: thuê máy chủ GPU Colab,... để huấn luyện mô hình).	1.300.000
2.	Chi phí in ấn tài liệu, báo cáo (báo cáo hàng tháng, báo cáo nghiệm thu các cấp).	300.000
3.	Chi phí thu thập và xử lý dữ liệu, hosting website.	500.000
4	Chi phí khác (ví dụ: chi phí phát sinh trong quá trình thu thập dữ liệu, tham khảo tài liệu,...).	500.000
Tổng cộng		2.600.000

Bằng chữ: hai triệu sáu trăm nghìn đồng.
Trong đó, đề nghị phía nhà trường hỗ trợ: 2.600.000 đồng.

TP.Hồ Chí Minh, ngày …… tháng …… năm 20…

TÁC GIẢ

(Tất cả Tác giả ký, ghi rõ họ tên)

……

……

……

GIẢNG VIÊN HƯỚNG DẪN

(Ký, ghi rõ họ tên)

……

TL. NCKHSV

(Ký, ghi rõ họ tên)

……

LÃNH ĐẠO KHOA

(Ký, ghi rõ họ tên)

……